

✓ Actividad 1.3 Solución de problemas y selección de características

Exploración inicial

```
from google.colab import drive
drive.mount('/content/drive')
```

```
import pandas as pd

file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)
display(df_calificaciones)
```

	Escuela	Sexo	Edad	HorasDeEstudio	Reprobadas	Internet	Faltas	G1	G2	G3
0	GP	F	18	2	0	no	6	5	6	6
1	GP	F	17	2	0	yes	4	5	5	6
2	GP	F	15	2	3	yes	10	7	8	10
3	GP	F	15	3	0	yes	2	15	14	15
4	GP	F	16	2	0	no	4	6	10	10
...	...	...	...	...	...	...	...	...	...	...
390	MS	M	20	2	2	no	11	9	9	9
391	MS	M	17	1	0	yes	3	14	16	16
392	MS	M	21	1	3	no	3	10	8	7
393	MS	M	18	1	0	yes	0	11	12	10
394	MS	M	19	1	0	yes	5	8	9	9

395 rows x 10 columns

En esta tabla, podemos observar datos recopilados de diferentes escuelas donde se adjuntan datos relacionados con el estudiante y su calificación. Todos los datos pueden llegar a considerarse importantes para establecer una relación con respecto a la calificación obtenida del estudiante y esto es lo que se va a buscar en este análisis. Para empezar, debemos conocer los datos que se nos presentan, que significan y su supuesta relevancia conforme a la obtención de la calificación.

- **Escuela:** esta columna contiene las diferentes escuelas a las que asisten los alumnos. Puede ser relevante debido al nivel de enseñanza que tiene dicha escuela, pues los maestros y métodos de aprendizaje pueden influir directamente en las calificaciones del estudiante. Esta variable se considera una variable cualitativa.
- **Sexo:** esta columna proporciona información del alumno, aunque no parezca tan importante, se puede llegar a utilizar para establecer una relación con las calificaciones, donde el sexo puede llegar a influir en las calificaciones si resulta haber mucha diferencia de resultados entre los sexos. Esta variable se considera una variable cualitativa.
- **Edad:** esta columna también proporciona información del alumno, que puede llegar a ser relevante si se logra establecer una relación entre diferencia de edad y resultados académicos. Esta variable se considera una variable cuantitativa.
- **Horas de estudio:** una columna que brinda información directa sobre la obtención de conocimientos y que probablemente influya sobre la calificación obtenida. Sobre esta columna se propone la siguiente hipótesis: las horas de estudio y las calificaciones obtenidas son directamente proporcionales, a mayor cantidad de horas de estudio, mayores resultados en calificaciones se obtendrán. Esta variable se considera una variable cuantitativa.
- **Reprobadas:** columna que refleja el desempeño del alumno y muestra las materias que no ha obtuvo calificación aprobatoria en el pasado. Se considera una variable cuantitativa.

- **Internet:** estos datos muestran si el alumno tiene o no acceso a internet. Es importante para el estudio pues estos datos pueden ser capaces de establecer una correlación donde tener internet influya positiva o negativamente a la calificación obtenida por el estudiante. Es una variable cualitativa.
- **Faltas:** esta variable indica las veces que el alumno faltó a clase, es importante en este estudio debido a que la hipótesis sugerida es que esta variable con respecto a las calificaciones tiene una correlación indirecta, donde a menos faltas, mejores calificaciones obtendrá el alumno. Es una variable cuantitativa.
- **G1/G2/G3:** son las 3 calificaciones obtenidas del alumno. Esta es la variable más importante pues de esta variable se obtendrán las relaciones y correlaciones de las otras variables. Se puede considerar una variable dependiente, de los demás datos explicados previamente. Los alumnos son calificados sobre 20, siendo este número la máxima calificación posible. Es una variable cuantitativa. Cabe aclarar que la variable **G3** representa la **calificación final** obtenida por el alumno.

Estas variables recopiladas son algunas de las múltiples que incluye originalmente el estudio. Y es en estas que encontramos el reto de saber reconocer cuáles de estas variables son realmente necesarias e influyentes a la hora de obtener mejores calificaciones. A parte, nos encontramos con varias variables cualitativas, que nos resulta difícil representarlas en un modelo de regresión lineal, pues no son numéricas, por lo que necesitaremos caracterizarlas con números, por ejemplo en la columna de sexos: 0 para las mujeres y 1 para los hombres. También hay que tener en cuenta los posibles valores atípicos que se obtengan a la hora del análisis, pues dependiendo de la variable, pueden salir valores demasiado extremos, como podemos observar en la variable faltas donde el rango general se maneja entre 0 y 8 pero hay casos de alumnos con 75 faltas.

✓ Procesamiento de datos

Es importante analizar si los datos son compatibles para realizar un modelo de regresión lineal que permita observar correctamente el impacto de las diferentes variables. Para esto tenemos que convertir las **variables cualitativas**, para que el modelo sepa representar correctamente su función. Para esto, utilizaremos la técnica **One-Hot Encoding**. Este proceso será aplicado a las siguientes variables.

- Escuela
- Sexo
- Internet

En la variable **Escuela** se utilizará un 0 para representar la escuela GP y un 1 para MS.

En la variable **Sexo** se utilizará un 0 para representar el género masculino y un 1 para el género femenino.

En la variable **Internet** se utilizará un 0 para representar "no" y un 1 para "sí".

```
import pandas as pd

# Asegurarse de que df_calificaciones esté cargado
file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)

# Codificación de la variable 'Escuela'
# 0 para 'GP' y 1 para 'MS'
df_calificaciones['Escuela'] = df_calificaciones['Escuela'].map({'GP': 0, 'MS': 1})

# Codificación de la variable 'Sexo'
# 0 para masculino ('M') y 1 para femenino ('F')
df_calificaciones['Sexo'] = df_calificaciones['Sexo'].map({'M': 0, 'F': 1})

# Codificación de la variable 'Internet'
# 0 para 'no' y 1 para 'sí'
df_calificaciones['Internet'] = df_calificaciones['Internet'].map({'no': 0, 'yes': 1})

# Mostrar el DataFrame con las variables codificadas para verificar
display(df_calificaciones)
```

	Escuela	Sexo	Edad	HorasDeEstudio	Reprobadas	Internet	Faltas	G1	G2	G3	
0	0	1	18	2	0	0	6	5	6	6	
1	0	1	17	2	0	1	4	5	5	6	
2	0	1	15	2	3	1	10	7	8	10	
3	0	1	15	3	0	1	2	15	14	15	
4	0	1	16	2	0	0	4	6	10	10	
...	...	...	...	...	...	...	...	...	...	...	
390	1	0	20	2	2	0	11	9	9	9	
391	1	0	17	1	0	1	3	14	16	16	
392	1	0	21	1	3	0	3	10	8	7	
393	1	0	18	1	0	1	0	11	12	10	
394	1	0	19	1	0	1	5	8	9	9	

395 rows x 10 columns

Pasos siguientes:

[Generar código con df_calificaciones](#)[New interactive sheet](#)

En esta nueva tabla se presentan los datos completamente preparados para su análisis. Se confirmó la ausencia de registros vacíos o huecos en todas las variables, garantizando la integridad del conjunto de datos.

Con respecto a la limpieza de valores atípicos, se tomaron dos decisiones estratégicas basándose en el análisis de diagramas de caja:

Variable Faltas: Se identificó que los estudiantes con más de **20 faltas** se sitúan fuera de los límites estadísticos normales. Por ello, se eliminaron estos registros para evitar que casos de ausentismo extremo distorsionen la pendiente del modelo de regresión.

Variable G3 : Se observó una presencia significativa de valores en **0**. Se tomó la decisión de eliminar estos registros, ya que estos ceros no representan necesariamente el desempeño académico continuo, sino casos de deserción o inasistencia al examen final.


Al realizar estas depuraciones, el modelo de regresión lineal múltiple podrá enfocarse en las tendencias reales de aprendizaje y predicción, obteniendo resultados mucho más precisos y representativos de la población estudiantil activa.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Cargar el DataFrame df_calificaciones (si aún no está cargado)
file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)

# Aplicar la codificación de variables cualitativas como se describe en el notebook
df_calificaciones['Escuela'] = df_calificaciones['Escuela'].map({'GP': 0, 'MS': 1})
df_calificaciones['Sexo'] = df_calificaciones['Sexo'].map({'M': 0, 'F': 1})
df_calificaciones['Internet'] = df_calificaciones['Internet'].map({'no': 0, 'yes': 1})

# Crear el diagrama de cajas para la variable 'Faltas'
plt.figure(figsize=(8, 6))
sns.boxplot(y=df_calificaciones['Faltas'])
plt.title('Diagrama de Cajas de Faltas')
plt.ylabel('Número de Faltas')
plt.show()
```



En este diagrama de cajas se visualiza la distribución de las inasistencias y la presencia de valores atípicos. Gracias a esta representación, es posible identificar el límite estadístico de los datos comunes; los estudiantes con un número mayor a **20 faltas** se clasifican como atípicos y, por lo tanto, serán eliminados del conjunto de datos para evitar que sesguen los resultados del modelo de regresión lineal.

```
import pandas as pd

# Cargar el DataFrame df_calificaciones (si aún no está cargado)
file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)

# Aplicar la codificación de variables cualitativas como se describe en el notebook
df_calificaciones['Escuela'] = df_calificaciones['Escuela'].map({'GP': 0, 'MS': 1})
df_calificaciones['Sexo'] = df_calificaciones['Sexo'].map({'M': 0, 'F': 1})
df_calificaciones['Internet'] = df_calificaciones['Internet'].map({'no': 0, 'yes': 1})

# Guardar el número original de filas para comparación
initial_rows = len(df_calificaciones)

# Filtrar el DataFrame para eliminar estudiantes con más de 20 faltas
df_calificaciones_cleaned = df_calificaciones[df_calificaciones['Faltas'] <= 20]

# Eliminar estudiantes con G3 igual a 0 del DataFrame ya limpiado de faltas
df_calificaciones_final = df_calificaciones_cleaned[df_calificaciones_cleaned['G3'] != 0]

# Mostrar las primeras filas del DataFrame final
display(df_calificaciones_final)
```

	Escuela	Sexo	Edad	HorasDeEstudio	Reprobadas	Internet	Faltas	G1	G2	G3	
0	0	1	18	2	0	0	6	5	6	6	
1	0	1	17	2	0	1	4	5	5	6	
2	0	1	15	2	3	1	10	7	8	10	
3	0	1	15	3	0	1	2	15	14	15	
4	0	1	16	2	0	0	4	6	10	10	
...	...	...	...	...	...	...	...	...	...	...	
390	1	0	20	2	2	0	11	9	9	9	
391	1	0	17	1	0	1	3	14	16	16	
392	1	0	21	1	3	0	3	10	8	7	
393	1	0	15	1	0	1	0	11	12	10	
394	1	0	19	1	0	1	5	8	9	9	

La comparación después de la limpieza es la siguiente:

- Número de filas inicial: 395
- Número de filas después de eliminar faltas excesivas (>20): 380
- Número de filas después de eliminar calificaciones finales nulas (G3=0): 342.

Pasos siguientes:

[Generar código con df_calificaciones_final](#)

[New interactive sheet](#)

✓ Análisis de relaciones entre variables

Una vez finalizada la etapa de preparación y limpieza de los datos, es fundamental realizar un análisis sobre la relación que existe entre las variables explicativas antes de proceder con el entrenamiento del modelo. Este paso permite evaluar si hay redundancia en la información, lo cual es un factor crítico para asegurar la validez de una regresión lineal múltiple.

El objetivo principal de esta comparación es identificar la multicolinealidad. Este fenómeno ocurre cuando dos o más variables independientes están altamente correlacionadas entre sí. Cuando esto ocurre, el modelo tiene dificultades para diferenciar el efecto individual de cada variable sobre la calificación final, restándole precisión a los coeficientes obtenidos.

La importancia de este análisis radica en que nos permite decidir qué variables son realmente necesarias. Si se mantienen variables redundantes, factores importantes como las Horas de Estudio o el acceso a Internet podrían perder relevancia estadística, ya que el peso del modelo se concentraría injustificadamente en las calificaciones parciales.

Por lo tanto, este examen aporta el sustento técnico para simplificar el modelo, permitiendo conservar únicamente aquellas variables que aporten información única y valiosa, logrando así una interpretación más clara y confiable sobre los factores que realmente impactan en el rendimiento académico.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Re-load and preprocess the DataFrame as it was defined previously
# Corrected file_path to the actual location in /content/sample_data/
file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)

# Aplicar la codificación de variables cualitativas como se describe en el notebook
df_calificaciones['Escuela'] = df_calificaciones['Escuela'].map({'GP': 0, 'MS': 1})
df_calificaciones['Sexo'] = df_calificaciones['Sexo'].map({'M': 0, 'F': 1})
df_calificaciones['Internet'] = df_calificaciones['Internet'].map({'no': 0, 'yes': 1})


# Filtrar el DataFrame para eliminar estudiantes con más de 20 faltas
df_calificaciones_cleaned = df_calificaciones[df_calificaciones['Faltas'] <= 20]

# Eliminar estudiantes con G3 igual a 0 del DataFrame ya limpiado de faltas
df_calificaciones_final = df_calificaciones_cleaned[df_calificaciones_cleaned['G3'] != 0]

# Calcular la matriz de correlación
correlation_matrix = df_calificaciones_final.corr()

# Crear el mapa de calor (heatmap)
```

```
plt.figure(figsize=(12, 10))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f", linewidths=.5)
plt.title('Matriz de Correlación de Variables en df_calificaciones_final')
plt.show()
```



Al observar la matriz de correlaciones, se nota una gran similitud entre **G1**, **G2** con respecto a **G3**, lo que indica que estas variables comparten información muy parecida. Esto es lógico, ya que los alumnos suelen mantener promedios constantes y sus notas en los primeros parciales se van acercando a la calificación final que obtendrán.

Teniendo esto en cuenta, se decidió eliminar la variable **G1** y conservar **G2** para el entrenamiento del modelo. Hacemos esto para evitar la **redundancia de información** y no confundir al modelo de regresión lineal. Al simplificar los datos de esta manera, permitimos que el algoritmo realice un análisis más exacto y que realmente podamos ver cuánto influyen otros factores, como las horas de estudio o el acceso a internet, en el resultado final.

Selección de variables

Para que el modelo de regresión lineal sea lo más preciso posible, se debe seleccionar las variables más relevantes para que nuestro modelo pueda predecir correctamente la calificación final (G3), debido a que no todas las variables influyen de la

misma manera. Para esto, utilizaremos nuestra matriz de correlación y observaremos que variables seleccionamos para el modelo:

- **G2:** Seleccionamos esta variable debido a su alta correlación de **0.96** con la calificación final.
- **Reprobadas:** Esta variable nos indica el historial de materias reprobadas, siendo este un indicador fuerte y teniendo una correlación negativa de **-0.29**.
- **Faltas:** Esta variable indica como las ausencias llegan a influir en la calificación final, con una correlación de **-0.24**.
- **Horas de estudio:** A pesar de tener una correlación más baja, se decide conservar porque es una variable que los estudiantes pueden controlar y nos ayuda a ver si el esfuerzo realmente se traduce en mejores notas.
- **Edad:** Se incluyó porque el análisis mostró que tiene una relación negativa con la calificación, **-0.15**, lo que sugiere que los alumnos de mayor edad en el mismo grado podrían tener un desempeño diferente.
- **Internet:** Se decidió incluir esta variable para evaluar si el acceso a recursos digitales influye en el rendimiento académico. Aunque su correlación no es la más alta (**0.12**), en el contexto actual es una variable social clave que nos permite observar si existe una brecha digital que afecte la calificación final del estudiante.

Con respecto a las variables eliminadas, se decide eliminar **G1** porque era redundante con **G2**, también se elimina **Sexo** y **Escuela** ya que tenían una relación muy débil con la calificación final comparado con las otras variables.

✓ Entrenamiento y evaluación del modelo

```
import statsmodels.api as sm
import pandas as pd

# Re-load and preprocess the DataFrame as it was defined previously
# Corrected file_path to the actual location in /content/sample_data/
file_path = '/content/sample_data/A1.3 Calificaciones.csv'
df_calificaciones = pd.read_csv(file_path)

# Aplicar la codificación de variables cualitativas como se describe en el notebook
df_calificaciones['Escuela'] = df_calificaciones['Escuela'].map({'GP': 0, 'MS': 1})
df_calificaciones['Sexo'] = df_calificaciones['Sexo'].map({'M': 0, 'F': 1})
df_calificaciones['Internet'] = df_calificaciones['Internet'].map({'no': 0, 'yes': 1})

# Filtrar el DataFrame para eliminar estudiantes con más de 20 faltas
df_calificaciones_cleaned = df_calificaciones[df_calificaciones['Faltas'] <= 20]

# Eliminar estudiantes con G3 igual a 0 del DataFrame ya limpiado de faltas
df_calificaciones_final = df_calificaciones_cleaned[df_calificaciones_cleaned['G3'] != 0]

# 1. Definimos nuestras variables (X) y el objetivo (y)
columnas_seleccionadas = ['G2', 'Reprobadas', 'HorasDeEstudio', 'Faltas', 'Internet']
X = df_calificaciones_final[columnas_seleccionadas]
y = df_calificaciones_final['G3']

# 2. Agregamos una columna de constantes (intercepto)
X_con_constante = sm.add_constant(X)

# 3. Ajustamos el modelo
modelo_detallado = sm.OLS(y, X_con_constante).fit()

# 4. Desplegamos el resumen estadístico
print(modelo_detallado.summary())
```

```

=====
                        OLS Regression Results
=====
Dep. Variable:          G3      R-squared:                0.931
Model:                  OLS      Adj. R-squared:           0.930
Method:                 Least Squares      F-statistic:         908.3
Date:                   Thu, 05 Feb 2026      Prob (F-statistic):    9.64e-193
Time:                   19:20:48      Log-Likelihood:       -424.40
No. Observations:       342      AIC:                  860.8
Df Residuals:           336      BIC:                  883.8
=====
```

Df Model:	5					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	0.2903	0.240	1.212	0.226	-0.181	0.761
G2	0.9853	0.016	62.210	0.000	0.954	1.016
Reprobadas	0.0001	0.073	0.002	0.999	-0.143	0.143
HorasDeEstudio	0.0423	0.055	0.764	0.445	-0.067	0.151
Faltas	0.0016	0.010	0.168	0.866	-0.017	0.021
Internet	-0.0446	0.124	-0.359	0.720	-0.289	0.199
Omnibus:	4.222		Durbin-Watson:		1.809	
Prob(Omnibus):	0.121		Jarque-Bera (JB):		4.370	
Skew:	0.162		Prob(JB):		0.112	
Kurtosis:	3.449		Cond. No.		70.3	

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Esta tabla presenta los resultados del análisis de regresión, los puntos más importantes son los siguientes:

- **La precisión del modelo (R^2):** La R cuadrada tiene un valor de 0.931. Esto significa que las variables seleccionadas logran explicar con confianza del 93% la calificación a obtener.
- **Calificación G2:** Tiene un coeficiente de 0.9853 y un P-valor de 0.000. Esto nos dice que por cada punto que un alumno saca en el segundo parcial, su calificación final sube casi un punto exacto (0.98). Es la única variable estadísticamente significativa, ya que su P-valor es menor a 0.05.
- **Internet y Horas de Estudio:** Sus coeficientes son bajos y sus P-valores son altos (0.720 y 0.445). Esto indica que, aunque influyen, su impacto es mínimo comparado con la nota del segundo parcial.
- **Faltas y Reprobadas:** Curiosamente, en este modelo final su impacto es casi cero. Esto sucede porque la calificación de G2 ya "absorbió" el efecto de estas variables; es decir, si un alumno falta mucho o ha reprobado, eso ya se refleja en su nota de G2.

Reflexión y conclusiones

El desarrollo de esta investigación, los análisis que se realizaron y los resultados en la tabla de regresión permiten identificar con un alto nivel de confianza las variables más influyentes en el desempeño académico de los estudiantes.

La limpieza de datos y selección de variables juegan un papel muy grande. Sin esta limpieza, el modelo habría tenido en cuenta valores atípicos, fuera de lo normal, que lo hubieran confundido y se hubiera causado pérdida de precisión. También la identificación de colinealidad entre **G1** y **G2** permitió simplificar el modelo.

Los resultados muestran a **G2** como la variable que más influye a la hora de la predicción, aunque otras variables como **Edad** y **Horas de estudio** también tuvieron influencia. Otras variables como **Reprobadas** o **Internet** no tuvieron tanta influencia como se esperaba.

Con respecto a limitaciones futuras, incluir otras bases de datos con muestras más grandes y agregar otras variables con respecto a información del alumno como su estado mental, podrían ayudar a mejorar dicho modelo predictivo.

Referencias

Cortez, P., & Silva, A. M. G. (2008). Student Performance [Conjunto de datos]. UCI Machine Learning Repository.

<https://archive.ics.uci.edu/dataset/320/student+performance>

Google. (2025). Gemini (versión del 5 de febrero). <https://gemini.google.com/>

